

PatchTST

**A Time Series is Worth 64 Words:
Long-term Forecasting with Transformers**

Mikołaj Nowak, Rafał Szubert, Anna Roszkiewicz

Transformer

- Początkowo przetwarzanie języka naturalnego
“Attention is All You Need” – 2017
- Następnie transformer wizyjny
“An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale” – 2021
- Przetwarzanie przebiegów czasowych
“A Time Series is Worth 64 Words: Long-term Forecasting with Transformers” – 2022

Predykcja przebiegów czasowych - zbiory danych

Cecha	Traffic	Weather	Electricity
Liczba atrybutów	862	21	321
Główny atrybut	Zajętość dróg	Wskaźniki fizyczne	Zużycie (kWh)
Częstotliwość	1h	10 min	1h
Liczba rekordów	17545	52696	26305

Wszystkie zbiory można znaleźć w repozytorium:

<https://huggingface.co/datasets/pkr7098/time-series-forecasting-datasets>

Implementacja

InstanceNormalization


Patching layer

Patch embedding


Transformer encoder

Linear layer – attention head

InstanceNormalization



(a) PatchTST Model Overview



(b) Transformer Backbone (Supervised)

(c) Transformer Backbone (Self-supervised)

Weather

Oryginalny artykuł (20 epok):



L	24		48		96		192		336		720	
P	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
96	0.222	0.246	0.212	0.243	0.178	0.219	0.16	0.204	0.152	0.199	0.147	0.198
192	0.265	0.279	0.254	0.277	0.224	0.259	0.204	0.245	0.197	0.243	0.19	0.24
336	0.325	0.322	0.31	0.316	0.278	0.298	0.257	0.285	0.249	0.283	0.242	0.282
720	0.404	0.374	0.385	0.365	0.35	0.346	0.329	0.338	0.32	0.335	0.304	0.328

Nasze wyniki (10 epok):

L	24		48		96		192		336		720	
P	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
96	0.2212	0.2532	0.2257	0.2508	0.1743	0.217	0.1723	0.2131	0.1729	0.2189	0.1735	0.2252
192	0.2698	0.2891	0.2572	0.2837	0.2196	0.2559	0.2302	0.2619	0.2366	0.2702	0.2552	0.2903
336	0.3305	0.3316	0.3138	0.3194	0.2809	0.2995	0.3131	0.3197	0.3148	0.3211	0.3272	0.3364
720	0.4133	0.3844	0.392	0.3692	0.3558	0.3499	0.4068	0.3739	0.3896	0.3749	0.4011	0.3839

Wizualizacja wyników

Effect of Lookback Length on Forecast Error (weather)



Traffic

Oryginalny artykuł (20 epok):

L	24		48		96		192		336		720	
P	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
96	0.766	0.419	0.671	0.381	0.477	0.305	0.401	0.267	0.367	0.251	0.365	0.251

Nasze wyniki (10 epok):

L	24		48		96		192		336		720	
P	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
96	0.7434	0.4113	0.6344	0.3665	0.4544	0.2934	0.3884	0.2716	0.361	0.262	0.371	0.267

Electricity

Oryginalny artykuł (20 epok):

L	24		48		96		192		336		720	
P	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
96	0.268	0.316	0.225	0.293	0.174	0.259	0.138	0.23	0.13	0.222	0.13	0.224

Nasze wyniki (10 epok):

L	24		48		96		192		336		720	
P	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
96	0.2653	0.3149	0.2178	0.2892	0.1665	0.2537	0.1368	0.2299	0.1317	0.2263	0.1394	0.2231

Tryb self-supervised

- Nie mamy ground truth
- Model uczy się tworzyć użyteczną reprezentację
- Wprowadzamy losowe braki w danych – maski
- Model uczy się je odtwarzać na podstawie pozostałych danych

Tryb self-supervised - implementacja

- Ta sama architektura transformera, ten sam enkoder
- Patches są rozłączne ($\text{stride} = \text{patch_len}$)
- Po podziale na paczki nakładamy losową maskę:
Losowo wybrane 40% paczek jest zakrywane
- Zamiast ostatniej warstwy (attention head)
Warstwa liniowa rekonstruuująca braki w danych
- MSE liczone dla brakujących fragmentów

Transfer Learning

- Sprawdzenie czy model nauczony na jednym datasecie, jest w stanie również osiągać dobre wyniki na innym
- Transfer wag Q, K, V
- Testy wykonane na datasecie weather

Transfer Learning (Weather)

Oryginalny artykuł (20 epok):

L	24		48		96		192		336		720	
P	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
96	0.222	0.246	0.212	0.243	0.178	0.219	0.16	0.204	0.152	0.199	0.147	0.198
192	0.265	0.279	0.254	0.277	0.224	0.259	0.204	0.245	0.197	0.243	0.19	0.24
336	0.325	0.322	0.31	0.316	0.278	0.298	0.257	0.285	0.249	0.283	0.242	0.282
720	0.404	0.374	0.385	0.365	0.35	0.346	0.329	0.338	0.32	0.335	0.304	0.328

Nasze wyniki (10 epok):

L	24		48		96		192		336		720	
P	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
96	0.2312	0.2541	0.2018	0.2399	0.1882	0.2215	0.1695	0.2114	0.1504	0.2012	0.1441	0.1991
192	0.2715	0.2833	0.2612	0.2798	0.2319	0.2642	0.2115	0.2512	0.1998	0.2481	0.1887	0.2425
336	0.3341	0.3195	0.3188	0.3211	0.2855	0.3014	0.2619	0.2911	0.2554	0.2885	0.2498	0.2844
720	0.4122	0.3814	0.3912	0.3688	0.3615	0.3512	0.3354	0.3421	0.3255	0.3412	0.3115	0.3311

Bibliografia

[1] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam,

“A time series is worth 64 words: Long-term forecasting with transformers,” 2022.

[2] A. K. D. W. X. Z. T. U. M. D. M. M. G. H. S. G. J. U.

Alexey Dosovitskiy, Lucas Beyer and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” 2021.

[3] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones,

A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” 2017.